Zahvaljujem se doc. dr. sc. Križanoviću na pružanom znanju tijekom izrade rada.

Sadržaj

Uvod 1

1. Biološki kontekst 2

1.1. DNA 2

1.1.1. Struktura DNA 2

1.1.2. Funkcija DNA 3

1.2. Genom i geni 3

1.3. Sekvenciranje genoma 4

1.4. Anotacija gena 4

1.4.1. Komparativne metode anotacije gena 4

1.4.2. Ab initio metoda anotacije gena 5

2. Duboko učenje 6

2.1. Umjetni neuron 6

2.2. Aktivacijske funkcije 7

2.2.1. Funkcija identiteta 8

2.2.2. ReLu funkcija 9

2.2.3. Tangens hiperbolni 10

2.2.4. Sigmoidalna funkcija 11

2.3. Umjetne neuronske mreže 12

2.4. Propagacija pogreške unatrag 13

2.5. Poznate arhitekture umjetnih neuronskih mreža 14

2.5.1. Višeslojni perceptroni 14

2.5.2. Konvolucijske neuronske mreže 14

2.5.3. Rekurentne neuronske mreže 15

3. Implementacija modela 17

3.1. Podaci 17

3.1.1. Preuzimanje podataka ... 17
3.1.2. Formati preuzetih datoteka ... 18
3.1.3. Priprema podataka za model ... 20
3.2. Korištene biblioteke ... 21
3.3. Model ... 21
3.3.1. One-hot sloj ... 22
3.3.2. Rekurentni slojevi ... 23
3.3.3. Konvolucijski slojevi ... 23
3.3.4. Potpuno povezani slojevi ... 23
3.3.5. Izlazni sloj ... 23
3.3.6. Važni hiperparametri ... 24
3.3.7. Treniranje modela ... 24
3.4. Evaluacija modela ... 25
3.4.1. Podaci za evaluaciju ... 25
3.4.2. Rezultati modela ... 26
3.4.3. Naknadna obrada podataka ... 26
3.4.4. Konačna evaluacija ... 27
3.4.5. Poboljšanje rezultata modela ... 28
3.4.6. GitHub ... 29
Zaključak ... 30
Literatura ... 31
Sažetak ... 32
Abstract ... 33

Uvod

U posljednjih nekoliko desetljeća, bioinformatika je doživjela značajan napredak, omogućujući znanstvenicima da dublje istraže genetsku informaciju sadržanu u DNA sekvencama. Jedno od ključnih područja unutar ove znanstvene discipline je detekcija gena, odnosno identificiranje kodirajućih regija za proteine unutar DNA sekvence. Tradicionalni pristupi, poput komparativne genomike i sličnih metoda, iako učinkoviti, imaju svoja ograničenja, posebno kada se radi o otkrivanju novih gena u organizmima sa slabo istraženim genomima.

Razvoj dubokih neuronskih mreža donio je revolucionarne promjene u mnogim područjima, uključujući i bioinformatiku. Njihova sposobnost prepoznavanja složenih uzoraka u velikim količinama podataka čini ih idealnim alatom za detekciju gena. Metode temeljene na dubokom učenju, posebno *ab initio* pristupi , omogućuju identificiranje gena bez potrebe za unaprijed poznatim informacijama o sličnosti s već poznatim genima. *Ab initio* pristup se temelji na izgradnji modela s pomoću podataka o drugim organizmima te detekciji gena bez prethodnog znanja o samom organizmu. Ovi pristupi koriste neobrađene sekvence DNA i uče karakteristike koje razlikuju kodirajuće regije od nekodirajućih, pružajući time mogućnost otkrivanja novih i potencijalno značajnih gena.

Cilj ovog rada je razviti model duboke neuronske mreže sposoban za ab initio detekciju gena na cjelokupnom genomu te detaljno opisati biološke i tehnološke koncepte koji su temelj njegove implementacije.

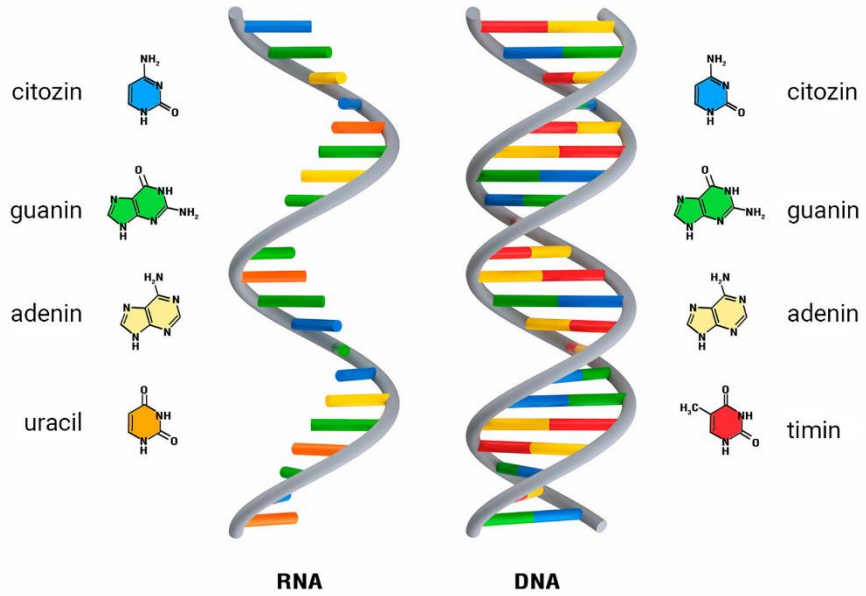
1. Biološki kontekst

1.1. DNA

Deoksiribonukleinska kiselina (DNA) (prikazana s desne strane Sl. 1.1) je molekula koja nosi genetske informacije potrebne za razvoj, funkcioniranje i reprodukciju svih živih organizama i mnogih virusa. Otkrivena sredinom 20. stoljeća, DNA je postala središnji fokus genetike i molekularne biologije. DNA je dugačka molekula koja se sastoji od dva lanca, uvijena jedan oko drugoga u obliku dvostruke zavojnice. Ovi lanci su sastavljeni od osnovnih jedinica nazvanih nukleotidi, a svaki nukleotid se sastoji od tri dijela: fosfatne skupine, šećera deoksiriboze i jedne od četiri dušične baze (adenin, timin, citozin i gvanin). Redoslijed ovih baza kodira genetske informacije.

1.1.1. Struktura DNA

DNA se sastoji od dva lanca nukleotida koji su međusobno povezani vodikovim vezama između dušičnih baza. Adenin (A) se uvijek spaja s timinom (T), a citozin (C) s gvaninom (G). Ova specifična komplementarnost baza omogućuje precizno kopiranje DNA tijekom stanične diobe, jer svaki lanac služi kao predložak za stvaranje novog komplementarnog lanca.



Sl. 1.1: Struktura RNA i DNA [1]

1.1.2. Funkcija DNA

Primarna funkcija DNA je skladištenje i prijenos genetskih informacija. Ove informacije se koriste za sintezu proteina kroz dva glavna procesa: transkripciju i translaciju. Tijekom transkripcije, dio DNA se prepisuje u molekulu RNA (ribonukleinske kiseline) (prikazana s lijeve strane Sl. 1.1), koja zatim služi kao predložak za sintezu proteina u procesu zvanom translacija. Proteini su esencijalne molekule koje obavljaju širok spektar funkcija u organizmima, uključujući kataliziranje kemijskih reakcija (enzimi), strukturalne komponente stanica, signalizaciju i regulaciju genetske ekspresije. Na taj način DNA indirektno kontrolira gotovo sve aspekte biološke funkcije kroz svoju ulogu u proizvodnji proteina.

1.2. Genom i geni

Genom je cjelokupni skup genetskog materijala organizma, koji uključuje sve njegove gene i ostale sekvence DNA. Kod eukariota, genom se nalazi unutar jezgre stanice u obliku kromosoma, dok je kod prokariota smješten u nukleoidu. Genom predstavlja zapis svega potrebno organizmu, sve informacije potrebne za njegov rast, razvoj, funkcioniranje i reprodukciju. Genom nije samo skup gena, on također uključuje nekodirajuće sekvence koje igraju važne regulatorne uloge. Količina DNA u genomu varira među vrstama, što rezultira različitim veličinama genoma. Na primjer, ljudski genom sadrži približno 3 milijarde baznih parova DNA, dok bakterijski genom može imati samo nekoliko milijuna baznih parova.

Geni su osnovne jedinice nasljedstva koje sadrže upute za sintezu proteina. Oni su specifični dijelovi DNA koji sadrže kod za određene proteine ili funkcionalne RNA molekule. Svaki gen ima specifičnu lokaciju na kromosomu i može varirati u duljini, ovisno o kompleksnosti kodirane informacije.

1.3. Sekvenciranje genoma

Sekvenciranje genoma je proces određivanja točnog reda nukleotida (adenin, timin, citozin i gvanin) u DNA molekuli. Ovaj proces pruža potpunu genetsku informaciju sadržanu u genomu, omogućujući znanstvenicima da analiziraju gene, regulatorne sekvence i druge funkcionalne elemente. Sekvenciranje genoma je ključna tehnika u modernoj biologiji i medicini, pružajući temelje za razumijevanje genetske osnove različitih bioloških procesa i bolesti. Sekvenciranje genoma može se primijeniti na cijeli genom ili na specifične dijelove genoma.

1.4. Anotacija gena

Anotacija gena je proces identifikacije i označavanja gena i njihovih funkcionalnih elemenata unutar sekvenciranog genoma. Ovaj proces uključuje određivanje mjesta gena, njihovih egzona i introna, promotorskih regija, kao i predviđanje funkcije gena na temelju sekvenci. Anotacija gena omogućuje znanstvenicima da razumiju koji dijelovi genoma kodiraju proteine ili funkcionalne RNA molekule te kako ti geni doprinose biološkim procesima i fenotipu organizma. Anotacija gena je temeljni korak u analizi sekvenciranih genoma, pružajući ključno razumijevanje genetskog sadržaja i funkcionalnih elemenata unutar DNA. Korištenjem kombinacije računalnih i eksperimentalnih metoda, znanstvenici mogu precizno identificirati gene i njihovu funkciju. Razvoj novih tehnologija i integrativnih pristupa nastavlja unapređivati preciznost i učinkovitost anotacije gena, omogućujući dublje uvide u genetske temelje života.

1.4.1. Komparativne metode anotacije gena

Komparativne metode predikcije gena koriste poznate biološke podatke i sekvence iz postojećih baza podataka za identifikaciju gena u novom genomu. Ove metode oslanjaju se na homologiju i sličnost s već poznatim genima i sekvencama. Homologna anotacija, na primjer, uspoređuje novo sekvencirane genomske sekvence s poznatim genima koristeći alate poput BLAST-a, identificirajući gene na temelju sličnosti s prethodno poznatim sekvencama. Prednosti komparativnih metoda uključuju visoku točnost u identificiranju poznatih gena i precizno određivanje granica egzona i introna. Međutim, one su ograničene dostupnošću postojećih podataka i mogu propustiti otkriti nove ili vrlo divergentne gene koji nemaju homologe u poznatim sekvencama.

1.4.2. Ab initio metoda anotacije gena

Ab initio metoda predikcije gena je računalni pristup koji koristi statističke modele i algoritme za identifikaciju gena u sekvenciranim genomima bez oslanjanja na poznate sekvence ili biološke podatke. Ova metoda analizira genomske sekvence kako bi prepoznala karakteristike tipične za gene, poput promotorskih regija, početnih i završnih kodona, te obrasce egzona i introna. Korištenjem skrivenih Markovljevih modela (HMM) i drugih statističkih tehnika, ab initio metode mogu predviđati kodirajuće regije DNA, identificirajući potencijalne gene na temelju njihovih strukturnih značajki. Primjeri alata koji koriste ab initio pristup uključuju GENSCAN, Augustus i Glimmer. Iako ab initio metode mogu proizvesti lažno pozitivne rezultate i imaju nižu točnost u usporedbi s komparativnim metodama, njihova sposobnost otkrivanja novih ili divergentnih gena čini ih vrijednim alatima u genomskim istraživanjima, posebno kada su dostupni podaci o homologiji ograničeni ili nepostojeći.

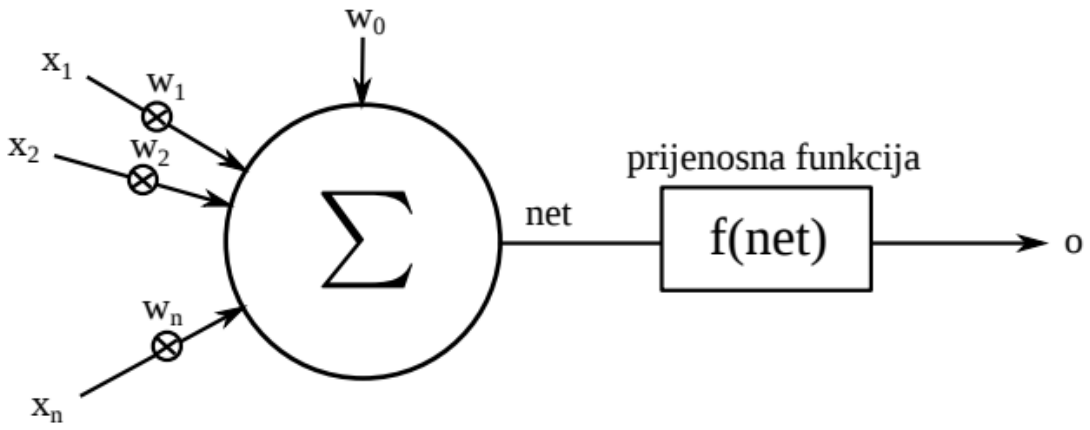
2. Duboko učenje

Duboko učenje je podgrana strojnog učenja koja koristi višeslojne neuronske mreže za analizu i učenje iz velikih količina podataka, temeljeno na imitiranju strukture i funkcije mozga i neurona. Svaka jedinica ili "neuron" u mreži prima ulazne podatke, primjenjuje težinski faktor, zbraja ih, prolazi kroz aktivacijsku funkciju i šalje rezultat sljedećem sloju, čime oponaša način na koji biološki neuroni komuniciraju i obrađuju informacije. Duboke neuronske mreže sastoje se od više slojeva neuronskih jedinica, gdje svaki sloj uči različite razine apstrakcije iz ulaznih podataka. Ovi slojevi su organizirani u hijerarhijsku strukturu, pri čemu se niži slojevi bave jednostavnijim značajkama, dok viši slojevi kombiniraju te značajke u složenije reprezentacije.

2.1. Umjetni neuron

Umjetni neuron (Sl. 2.1) je osnovna jedinica u neuronskim mrežama koja simulira ponašanje bioloških neurona u mozgu. Svaki umjetni neuron prima ulazne podatke, obrađuje ih i generira izlaz. Ključni dijelovi umjetnog neurona uključuju:

- Ulazne Težine: Svaki ulaz podataka x_i pomnožen je s odgovarajućom težinom w_i, koja predstavlja važnost tog ulaza u procesu donošenja odluke.
- Zbrajanje: Pomnoženi ulazi se zbrajaju te se rezultat zbraja s pomakom.
- Aktivacijska (prijenosna) funkcija: Rezultat zbrajanja se zatim prosljeđuje kroz aktivacijsku funkciju, koja uvodi nelinearnost u model. Ova funkcija određuje izlazni signal neurona na temelju ulaznih podataka i pomaka.
- Izlaz: Izlazni signal iz aktivacijske funkcije predstavlja konačni izlaz umjetnog neurona, koji se može koristiti kao ulaz za sljedeći umjetni neuron.



Sl. 2.1: Prikaz umjetnog neurona [2]

Prikazani izraz (1) predstavlja jednadžbu kojom se izračunava vrijednost varijable. U jednadžbi broj n predstavlja broj ulaznih podataka dok x_i predstavlja jedan ulazni podatak, a w_i odgovarajuću težinu. Pomak je prikazan s w_0. Nakon izračuna vrijednosti varijable net, nad njom se primjenjuje odgovarajuća aktivacijska funkcija (2).

$$net = \left(\sum_{i=1}^{n} x_i * w_i\right) + w_0 \tag{1}$$

$$o = f(net) \tag{2}$$

2.2. Aktivacijske funkcije

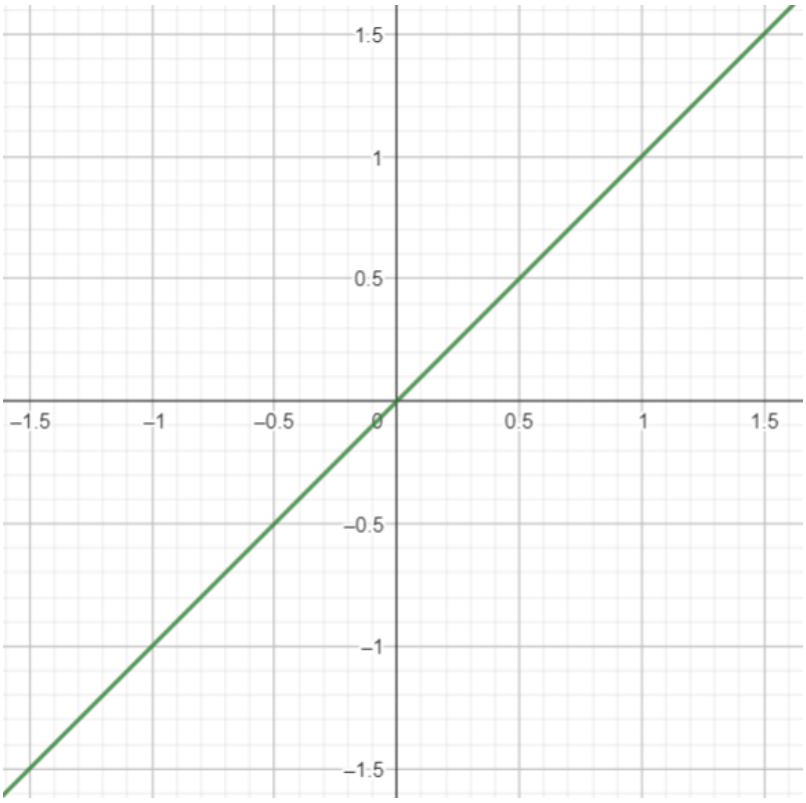
Aktivacijske funkcije su matematičke funkcije koje se primjenjuju na izlazima neurona u neuronskim mrežama. One su odgovorne za uvođenje nelinearnosti u model, što je ključno za sposobnost neuronskih mreža da nauče i modeliraju složene i nelinearne relacije u podacima.

2.2.1. Funkcija identiteta

Funkcija identiteta (Sl. 2.2) je najjednostavnija aktivacijska funkcija koja preslikava ulaze na izlaz bez ikakvih promjena.

$$f(net) = net \tag{3}$$

Iako se funkcija identiteta čini jednostavnom i može se činiti nekorisnom u kontekstu aktivacijskih funkcija, ona zapravo ima svoje primjene. Na primjer, funkcija identiteta može se koristiti u slojevima neuronskih mreža kada se želi izvršiti samo preslikavanje bez ikakve promjene ili transformacije ulaznih podataka. Također se može koristiti u izlaznom sloju neuronske mreže kada se izlazi modela ne trebaju dodatno obraditi ili transformirati.



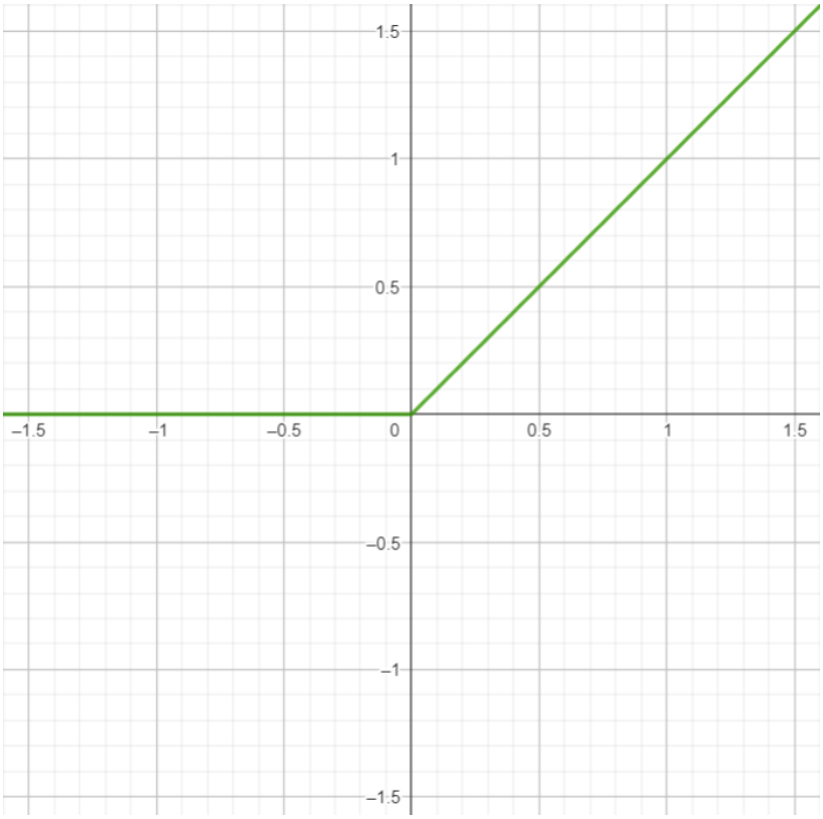
Sl. 2.2: Prikaz funkcije identiteta

2.2.2. ReLu funkcija

ReLu (zglobnica) (4) funkcija je jedna od najpopularnijih i najčešće korištenih aktivacijskih funkcija u dubokom učenju. Matematički, ReLu funkcija je definirana kao:

$$f(net) = \max(0, net) \tag{4}$$

To znači da ReLU vraća ulaznu vrijednost x ako je x pozitivna, a vraća 0 ako je x negativna. Grafički, ova funkcija izgleda kao linearna linija koja prolazi kroz sve pozitivne vrijednosti i ravna je na nuli za sve negativne vrijednosti (Sl. 2.3).



Sl. 2.3: Graf funkcije ReLu

U usporedbi s sigmoidalnom i tanh funkcijom, ReLU pomaže u smanjenju problema nestajućih gradijenata. Ali nekada velika negativna vrijednost ulaza može rezultirati time

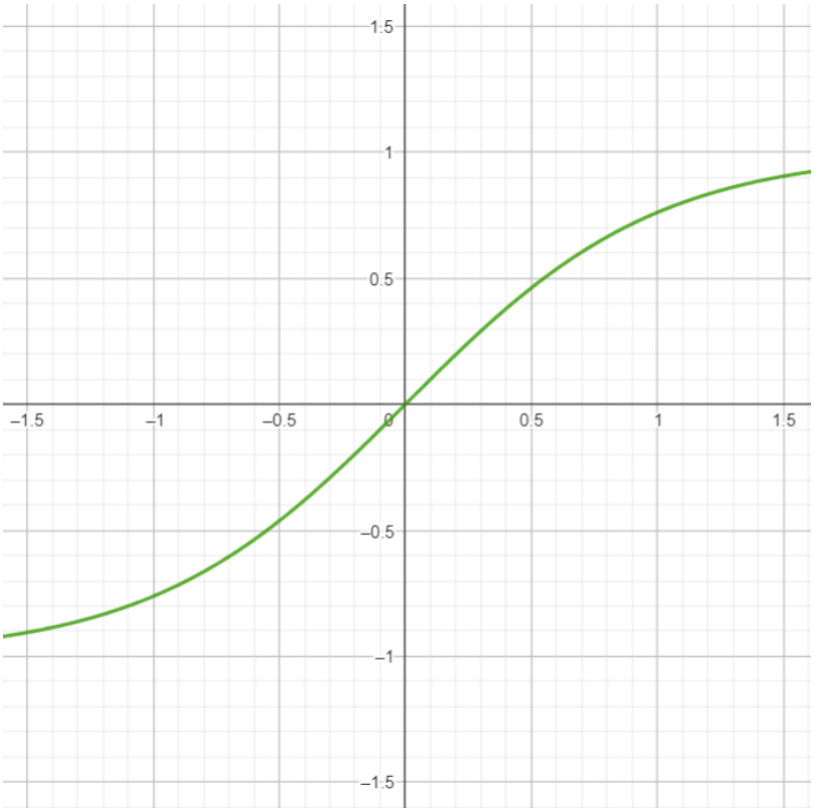
da se neuron nikada više ne aktivira (tj. izlaz je uvijek 0), taj neuron postaje "mrtav". To može uzrokovati gubitak kapaciteta modela.

2.2.3. Tangens hiperbolni

Tangens hiperbolni (5) kao aktivacijska funkcija je popularna funkcija koja se koristi u neuronskim mrežama, posebno u skrivenim slojevima između ulaznog i izlaznog sloja.

$$tanh(net) = \frac{e^{net} - e^{-net}}{e^{net} + e^{-net}} \tag{5}$$

Tangens hiperbolni preslikava ulazne vrijednosti u raspon od -1 do 1 (Sl. 2.4), što znači da negativni ulazi će biti preslikani na negativne izlaze, a pozitivni ulazi na pozitivne izlaze, dok su vrijednosti oko nule približno linearne. Ova aktivacijska funkcija pati od problema nestajućeg gradijenta za ekstremne ulazne vrijednosti (vrlo pozitivne ili vrlo negativne).



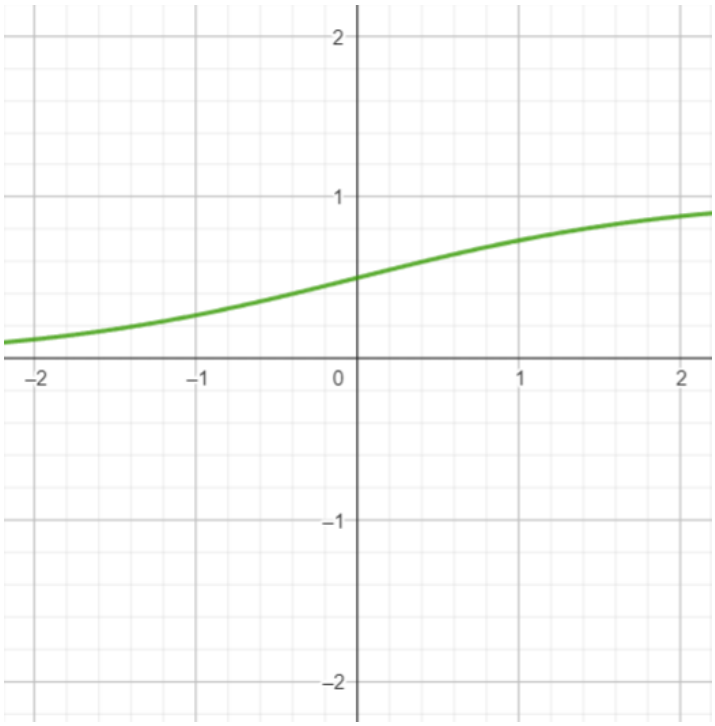
Sl. 2.4: Graf funkcije tanh

2.2.4. Sigmoidalna funkcija

Sigmoidalna aktivacijska funkcija (6) je jedna od najstarijih i najčešće korištenih aktivacijskih funkcija u neuronskim mrežama, posebno u ranim modelima.

$$\sigma(net) = \frac{1}{1 + e^{-net}} \tag{6}$$

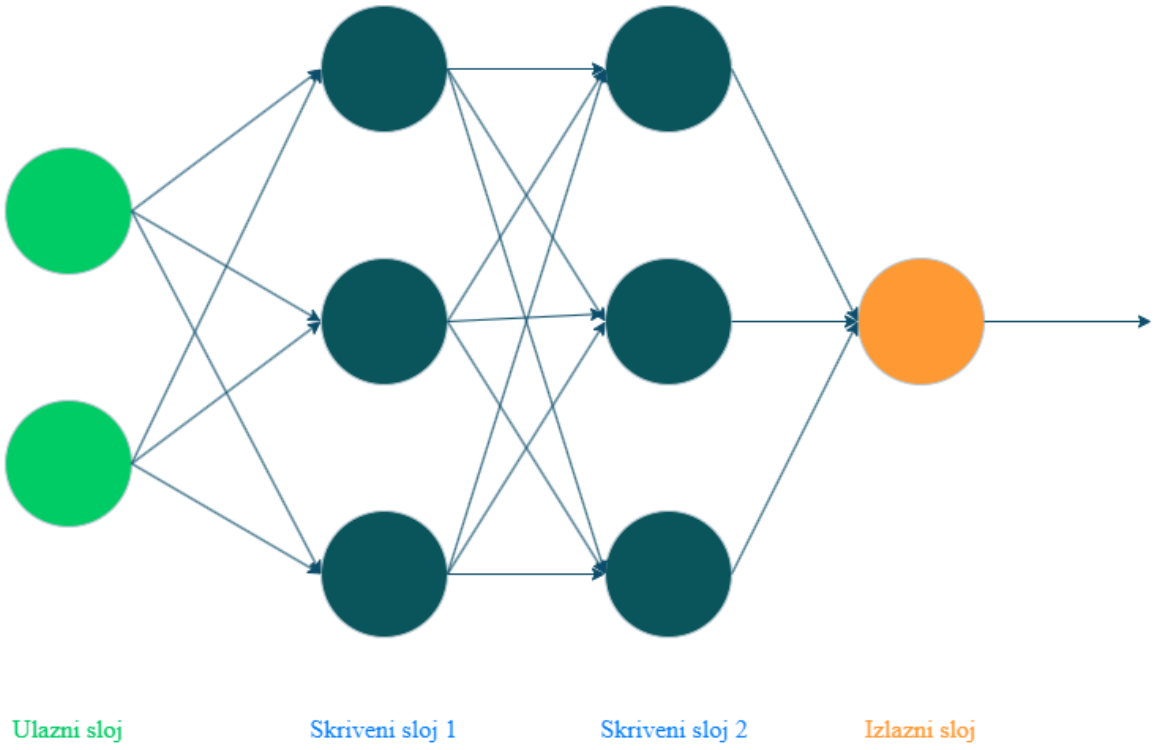
Ova funkcija preslikava ulazne vrijednosti u raspon između 0 i 1 (prikazano na Sl. 2.5), što je korisno za standardizaciju izlaza neurona i ograničavanje vrijednosti na fiksni raspon. Sigmoidalna funkcija je glatka i diferencijabilna, što je povoljno za algoritme optimizacije poput gradijentnog spusta. Njena glavna prednost je interpretabilnost, jer se izlazi mogu tumačiti kao vjerojatnosti, što je posebno korisno u binarnoj klasifikaciji. Sigmoidalna funkcija ima i nedostatke, poput problema nestajućih gradijenata za ekstremne ulazne vrijednosti, gdje derivacija postaje vrlo mala, što usporava učenje u dubokim mrežama.



Sl. 2.5: Graf sigmoidalne funkcije

2.3. Umjetne neuronske mreže

Sada kad razumijemo kako umjetni neuron radi, možemo pogledati kako se umjetni neuroni spajaju u umjetnu neuronsku mrežu. Svaka neuronska mreža se sastoji od tri glavna sloja: ulazni sloj, skriveni slojevi i izlazni sloj (prikazano na Sl. 2.6).



Sl. 2.6: Dijagram jednostavne neuronske mreže

Sloj neuronske mreže je osnovna komponenta u strukturi umjetne neuronske mreže. On je reprezentiran sa skupom umjetnih neurona koji nisu direktno međusobno povezani, nego su povezani s neuronima u prethodnom ili sljedećem sloju. Svi umjetni neuroni u jednom sloju primaju iste podatke na svoje ulaze i zatim svoje izlaze šalju dalje kao ulazni podaci u sljedećem sloju. Ulazni sloj je prvi sloj neuronske mreže i on zapravo ne sadrži umjetne neurone. Taj sloj služi samo za slanje sirovih podataka u prvi skriveni sloj. Zatim skriveni slojevi obrađuju podatke primljene iz ulaznog sloja i izvode složene transformacije. Mreža može sadržavati jedan ili više skrivenih slojeva, a broj i veličina skrivenih slojeva određuju kapacitet i složenost modela. Svaki neuron u skrivenom sloju prima ulaze iz svih neurona prethodnog sloja, množi ih odgovarajućim težinama, zbraja ih, dodaje pomak, a zatim

primjenjuje aktivacijsku funkciju na rezultat. Na kraju neuronske mreže se nalazi izlazni sloj. On proizvodi konačnu predikciju ili klasifikaciju modela. Broj neurona u izlaznom sloju ovisi o vrsti problema koji se rješava. Na primjer, za binarnu klasifikaciju izlazni sloj obično ima jedan neuron, dok za više klasnu klasifikaciju broj neurona odgovara broju klasa.

2.4. Propagacija pogreške unatrag

Propagacija pogreške unatrag ključni je algoritam za treniranje umjetnih neuronskih mreža. Omogućava mreži da uči iz svojih pogrešaka i prilagodi težine kako bi poboljšala točnost predikcija. Proces se sastoji od nekoliko koraka, uključujući izračunavanje pogreške, propagaciju pogreške unatrag kroz mrežu i prilagođavanje težina s pomoću optimizacijskog algoritma.

Koraci propagacije pogreške unatrag:

1. Prosljeđivanje unaprijed: Ulazni podaci prolaze kroz mrežu sloj po sloj, gdje se za svaki neuron izračunava linearna kombinacija ulaza i težina, dodaje se pomak, a zatim se primjenjuje aktivacijska funkcija. Ova faza rezultira izlaznim predikcijama mreže.
2. Izračunavanje pogreške: Pogreška ili gubitak izračunava se s pomoću funkcije gubitka (npr. srednja kvadratna pogreška za regresijske probleme ili unakrsna entropija za klasifikacijske probleme). Pogreška predstavlja razliku između stvarnih izlaza i predikcija mreže.
3. Propagacija pogreške unatrag: Pogreška se propagira unatrag kroz mrežu kako bi se izračunali gradijenti funkcije gubitka u odnosu na težine i pomake u mreži. Ovaj proces koristi ulančanu derivaciju izračunavajući gradijent pogreške za svaki sloj, počevši od izlaznog sloja i idući prema ulaznom sloju.
4. Ažuriranje težina: Nakon što su izračunati gradijenti, težine i pomaci ažuriraju se s pomoću optimizacijskog algoritma kao što je gradijentni spust. U osnovnom obliku gradijentnog spusta, težine se ažuriraju u smjeru negativnog gradijenta kako bi se minimizirala funkcija gubitka.

Kroz iterativni proces prosljeđivanja unaprijed, izračuna pogreške, propagacije pogreške unatrag i ažuriranja težina, neuronske mreže postaju sposobne za učenje složenih obrazaca i donošenje preciznih predikcija.

2.5. Poznate arhitekture umjetnih neuronskih mreža

2.5.1. Višeslojni perceptroni

Višeslojni perceptroni su jednostavne mreže sa dva ili više skrivena sloja. Skriveni slojevi su potpuno povezani što znači da svi izlazi iz jednog sloja su ulazi u svaki neuron slijedećeg sloja, također se zovu potpuno povezani slojevi. Svi slojevi višeslojnih perceptrona koriste aktivacijske funkcije kako bi omogućili modeliranje nelinearnih odnosa među podacima[4]. Višeslojni perceptroni su jednostavni za implementaciju i razumijevanje te su dovoljno fleksibilni da mogu modelirati širok raspon problema.

2.5.2. Konvolucijske neuronske mreže

Konvolucijske neuronske mreže su vrsta dubokih neuronskih mreža koje često koriste kod obrade i analize slika, ali imaju i druge primjene. One jako dobro uče lokalne obrasce u ulaznim podacima.

Ova ključna činjenica daje konvolucijskim neuronskim mrežama dvije zanimljive karakteristike:

- Jednom kada nauče neki lokalni obrazac, oni ga mogu prepoznati svugdje u ulaznim podacima. Npr. nakon učenja određenog obrasca u donjem desnom kutu neke slike, konvolucijska neuronska mreža je može prepoznati bilo gdje, na primjer, u gornjem lijevom kutu. Potpuno povezani model bi morao iznova naučiti obrazac ako bi se pojavio na novom mjestu [3].
- Mogu naučiti prostorne hijerarhije uzoraka. Prvi sloj konvolucije naučit će male lokalne uzorke kao što su rubovi, drugi sloj učit će na većim uzorcima napravljenim od obilježja prvih slojeva, i tako. To omogućuje konvolucijskim neuronskim mrežama da učinkovito naučite sve složenije i apstraktnije koncepte [3].

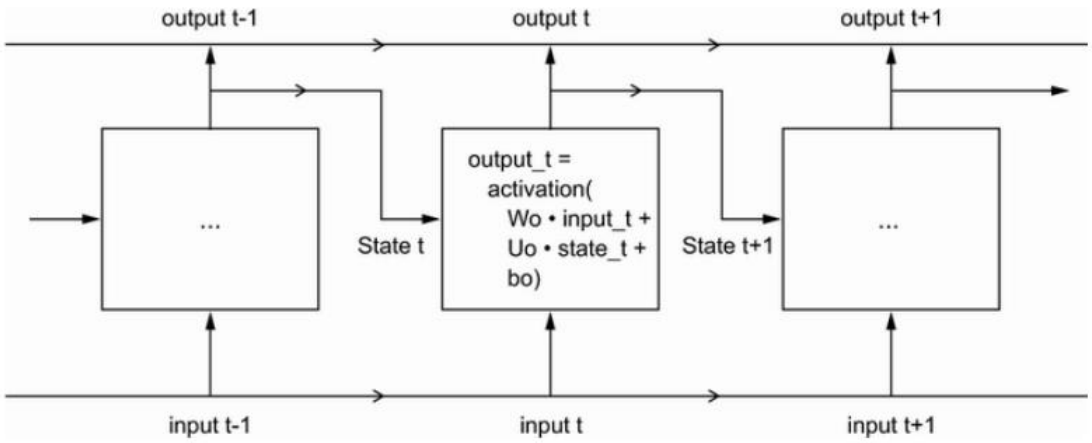
Struktura konvolucijske neuronske mreže se sastoji od nekoliko slojeva. Na početku mreže se nalaze konvolucijski slojevi. Oni uče lokalne obrasce tako da primjenjuju filtre na ulazne podatke kako bi ekstrahirali značajke. Filtri su male matrice težina koje se pomiču preko ulaznih podataka, izračunavajući skalarni produkt između težina filtra i preklapajućih dijelova ulaza. Rezultat je mapa značajki koja ističe različite aspekte ulaza,

poput rubova, tekstura i složenijih obrazaca. Svaki filter u konvolucijskom sloju odgovara jednoj mapi značajki. Nakon konvolucijskih slojeva se primjenjuju aktivacijske funkcije (poput ReLu). Zatim slijede slojevi koji smanjuju dimenzionalnost mape značajki, čineći izračune efikasnijima. Na kraju se nalaze potpuno povezani slojevi koji integriraju značajke ekstrahirane kroz konvolucijske slojeve kako bi donijeli konačne klasifikacijske ili regresijske odluke.

2.5.3. Rekurentne neuronske mreže

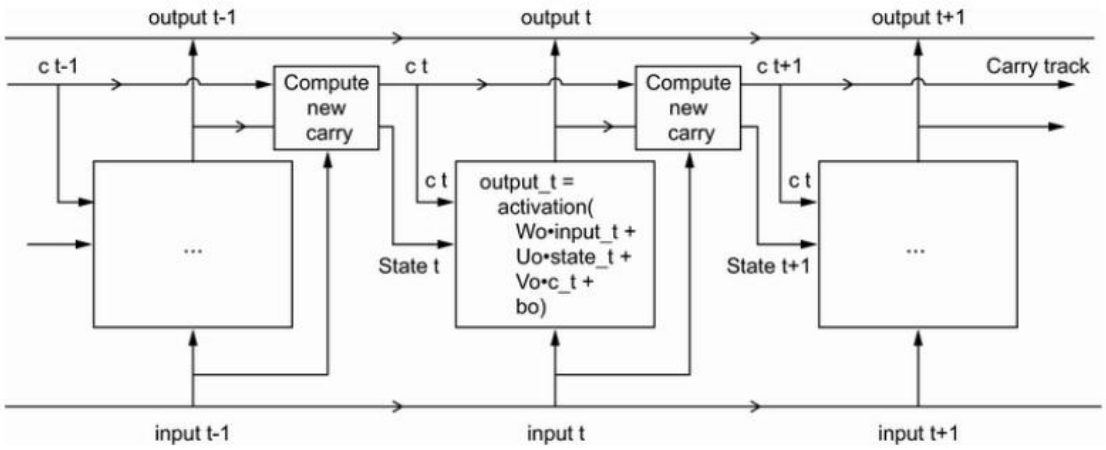
Rekurentne neuronske mreže su vrsta umjetnih neuronskih mreža dizajniranih za obradu sekvencijalnih podataka. Za razliku od klasičnih neuronskih mreža, rekurentne neuronske mreže imaju petlje koje omogućuju očuvanje informacija iz prethodnih vremenskih koraka, čime se omogućuje modeliranje ovisnosti i kontekst.

Rekurentne neuronske mreže procesiraju podatke tako da iteriraju kroz elemente podataka i čuvaju stanje koje sadrži informacije o svemu što je do sada viđeno (Sl. 2.7) [3].



Sl. 2.7: Prikaz rekurentne neuronske mreže [3]

Zbog očuvanja stanja u rekurentnim neuronskim mrežama kroz jako puno iteracija dolazi do problema nestajućeg gradijenta. Varijacija rekurentnih mreža koja rješavaju taj problem su LSTM i GRU mreže. LSTM (Long Short-Term Memory) (Sl. 2.8) mreže sačuvaju informaciju kroz dugi niz iteracija. Te informacije se tada mogu koristiti u bilo kojem koraku kada su potrebne i to ostvaruju s pomoću jedinica zvane "ćelije" koje upravljaju protokom informacija kroz mrežu s pomoću ulaznih, izlaznih i zaboravnih vrata.



Sl. 2.8: Prikaz LSTM mreže [3]

3. Implementacija modela

3.1. Podaci

Podaci su temelj dubokog učenja, a kvaliteta, količina i raznolikost podataka izravno utječu na performanse i sposobnosti dubokih neuronskih mreža. Kvalitetni podaci trebaju biti točni, konzistentni i potpuni kako bi se postigli pouzdani rezultati. Duboke neuronske mreže zahtijevaju velike količine podataka za učinkovito učenje, jer veće količine podataka omogućuju modelu bolje generaliziranje i smanjuju rizik od prekomjernog prilagođavanja specifičnim uzorcima. Raznolikost podataka omogućuje modelu da uči iz širokog spektra primjera, čime se povećava robusnost i sposobnost generalizacije na nove situacije. Priprema i obrada podataka, uključujući čišćenje, normalizaciju, standardizaciju i augmentaciju, ključni su koraci u procesu dubokog učenja koji osiguravaju da podaci budu prikladni za modeliranje. Anotacija podataka, odnosno označavanje podataka relevantnim informacijama, presudna je za zadatke nadziranog učenja jer model uči iz označenih primjera. Bez adekvatnih podataka, čak i najsofisticiraniji algoritmi dubokog učenja mogu imati ograničene performanse, stoga je ključno posvetiti dovoljno pažnje prikupljanju, obradi i anotaciji podataka kako bi se postigli optimalni rezultati.

3.1.1. Preuzimanje podataka

Za potrebe ovog rada trebaju nam podaci o genomima bakterija i podaci o njihovim genima. Svi podaci su preuzeti sa NCBI web stranice (https://www.ncbi.nlm.nih.gov).

National Center for Biotechnology Information (NCBI) je dio National Library of Medicine (NLM), koja je pak dio National Institutes of Health (NIH) u Sjedinjenim Američkim Državama. NCBI je osnovan 1988. godine i pruža pristup širokom spektru bioloških informacija kako bi podržao istraživanje, obrazovanje i primjenu u području biotehnologije i biomedicine. Njegove osnovne funkcije uključuju pohranu, analizu i distribuciju bioloških podataka, kao i razvoj novih softverskih alata za analizu tih podataka.

GenBank je jedna od najvažnijih baza podataka koje NCBI upravlja. GenBank je otvorena pristupna baza podataka nukleotidnih sekvenci i njihovih proteinskih translacija. Ova baza

podataka omogućuje istraživačima diljem svijeta da pohranjuju, pretražuju i analiziraju genetske informacije[5].

RefSeq (Reference Sequence Database) je također baza podataka koju održava NCBI. RefSeq pruža sveobuhvatnu, neredundantnu zbirku referentnih sekvenci genoma, transkripta i proteina iz različitih organizama. Glavni cilj RefSeq-a je pružiti dobro anotirane referentne sekvence koje se mogu koristiti kao standardi za biološka istraživanja i aplikacije[6].

3.1.2. Formati preuzetih datoteka

Kod preuzimanja podataka o genomima koriste se već poznati formati datoteka. U sklopu ovog rada dovoljno je znati samo dva formata iz kojih se mogu izvući se potrebni podaci.

GFF datoteke

GFF je tekstualni format koji se koristi za opisivanje strukture genoma ili bilo kojeg drugog sekvenciranog skupa. Uobičajeno se koristi za označavanje i anotaciju različitih bioloških značajki unutar sekvence, poput gena, egzona, introna, promotora i regulatornih elemenata. Evo nekoliko ključnih karakteristika GFF datoteka**:**

- Struktura: GFF datoteka se sastoji od redaka, pri čemu svaki red predstavlja jednu značajku ili anotaciju unutar sekvence. Svaki red obično sadrži kolone koje definiraju poziciju, tip, naziv i druge atribute značajke.
- Pozicija: Svaka značajka je definirana svojom pozicijom na sekvenci, koja se obično sastoji od početnog i završnog položaja na kromosomu ili sekvenci.
- Tip Značajke: GFF omogućuje različite vrste značajki da budu anotirane, kao što su "gene" (gen), "exon" (egzon), "CDS" (kodon), "promoter" (promotor) i druge.
- Atributi: Osim osnovnih informacija o poziciji i tipu značajke, GFF datoteke mogu sadržavati i dodatne atribute, poput naziva gena, identifikatora, funkcionalnih anotacija i drugih relevantnih informacija[7].

Primjer prvih nekoliko redaka GFF datoteke se može vidjeti na Prikaz 3.1.

```
##gff-version 3
#!gff-spec-version 1.21
#!processor NCBI annotwriter
#!genome-build ASM584v2
#!genome-build-accession NCBI_Assembly:GCF_000005845.2
##sequence-region NC_000913.3 1 4641652
##species https://www.ncbi.nlm.nih.gov/Taxonomy/Browser/wwwtax.cgi?id=511145
NC_000913.3	RefSeq	region	1	4641652	.	+	.	ID=NC_000913.3:1..464
NC_000913.3	RefSeq	gene	190	255	.	+	.	ID=geneb0001;
NC_000913.3	RefSeq	CDS	190	255	.	+	0	ID=cds-NP_414542.1;
NC_000913.3	RefSeq	gene	337	2799	.	+	.	ID=gene-b0002;
NC_000913.3	RefSeq	CDS	337	2799	.	+	0	ID=cds-NP_414543.1
```

Prikaz 3.1: Primjer GFF datoteke

FASTA datoteke

FASTA je jednostavan tekstualni format koji se koristi za pohranu sekvenci nukleotida ili aminokiselina. Ovaj format se često koristi za pohranu genoma, transkriptoma, proteinskih sekvenci i drugih bioloških sekvenci. Ključne karakteristike FASTA datoteka uključuju:

- Jednostavnost: FASTA format je jednostavan i lako čitljiv, što ga čini popularnim formatom za razmjenu bioloških sekvenci.
- Header linija: Svaka sekvencija u FASTA datoteci obično počinje header linijom koja započinje znakom ">". Ova linija obično sadrži identifikator ili opis sekvence.
- Sekvenca: Nakon header linije slijedi linija koja sadrži samu sekvencu, pri čemu se svaki red obično ograničava na 60-80 znakova radi čitljivosti[8].

Primjer prvih nekoliko redaka FASTA datoteke se može vidjeti na Prikaz 3.2.

```
>NC_000913.3 Escherichia coli str. K-12 substr. MG1655, complete genome

AGCTTTTCATTCTGACTGCAACGGGCAATATGTCTCTGTGTGGATTAAAAAAAGAGTGTCTGATAGCA
GCTTCTGAACTGGTTACCTGCCGTGAGTAAATTAAAATTTTATTGACTTAGGTCACTAAATACTTTAAC
CAATATAGGCATAGCGCACAGACAGATAAAAATTACAGAGTACACAACATCCATGAAACGCATTAGC
ACCACCATTACCACCACCATCACCATTACCACAGGTAACGGTGCGGGCTGACGCGTACAGGAAACA
CAGAAAAAAGCCCGCACCTGACAGTGCGGGCTTTTTTTTTCGACCAAAGGTAACGAGGTAACAACCA
TGCGAGTGTTGAAGTTCGGCGGTACATCAGTGGCAAATGCAGAACGTTTTCTGCGTGTTGCCGATAT
TCTGGAAAGCAATGCCAGGCAGGGGCAGGTGGCCACCGTCCTCTCTGCCCCCGCCAAAATCACCAA
CCACTGGTGGCGATGATTGAAAAAACCATTAGCGGCCAGGATGCTTTACCCAATATCAGCGATGCCG
AACGTATTTTTGCCGAACTTTTGACGGGACTCGCCGCCGCCCAGCCGGGGTTCCCGCTGGCGCAAT
TGAAAACTTTCGTCGATCAGGAATTTGCCCAAATAAAACATGTCCTGCATGGCATTAGTTTGTTGGGG
CAGTGCCCGGATAGCATCAACGCTGCGCTGATTTGCCGTGGCGAGAAAATGTCGATCGCCATTATG
GCCGGCGTATTAGAAGCGCGCGGTCACAACGTTACTGTTATCGATCCGGTCGAAAAACTGCTGGCA
GTGGGGCATTACCTCGAATCTACCGTCGATATTGCTGAGTCCACCCGCCGTATTGCGGCAAGCCGC
ATTCCGGCTGATCACATGGTGCTGATGGCAGGTTTCACCGCCGGTAATGAAAAAGGCGAACTGGTG
```

Prikaz 3.2: Primjer FASTA datoteke

3.1.3. Priprema podataka za model

Prvo korak je preuzeti i učitati podatke. Podaci o genomima i genima su preuzete s NCBI web stranice u obliku GFF i FASTA datoteka. Nakon toga se datoteke trebaju učitat i iz njih izvući potrebne informacije. U ovom radu se koriste podaci o pet različitih bakterija za treniranje i validaciju modela. Iz GFF datoteka potrebne informacije su počeci i krajevi gena, a iz FASTA datoteka su učitane sekvence.

Nakon učitavanja pozicija gena iz GFF datoteke kreiran je vektor jedinica i nula jednake duljine kao i DNA sekvenca. Jedinice u tom vektoru predstavljaju da je određena baza u sekvenci dio gena, dok nula predstavlja da nije dio gena. Zatim se sekvenca i odgovarajući vektor jedinica i nula podijele na blokove duljine 500. Kod generiranja blokova se koristi korak 100 što znači da dva susjedna izgenerirana bloka imaju preklop od 400 baza time se daje modelu da uči dijelove sekvenca iz više različitih konteksta.

Svaki blok sekvence i odgovarajući blok vektora se zatim grupiraju u parove te su nasumično pomiješani. Tako napravljeni skup podataka je zatim proveden kroz sloj koji pretvara tekst sekvence (A,C,G,T) u brojeve (0-3). Zatim će kasnije model umjetne neuronske mreže u sebi pretvoriti brojeve u “one-hot“ vektore s kojima će onda dalje raditi. Skup podataka je zatim podijeljen u skup za treniranje i validaciju s tim da podaci za validaciju su od bakterije koja se ne nalazi u skupu za treniranje.

3.2. Korištene biblioteke

Python se smatra najboljim jezikom za duboko učenje zbog svoje bogate ekosfere biblioteka i okvira kao što su TensorFlow, Keras i PyTorch, koji olakšavaju razvoj složenih modela. Njegova jednostavna i čitljiva sintaksa omogućava istraživačima i inženjerima da se fokusiraju na rješavanje problema umjesto na tehničke detalje programiranja. Zato sam u ovom radu koristio Python te biblioteke TensorFlow i Keras.

TensorFlow

TensorFlow je open-source biblioteka za numeričke izračune koja je posebno dizajnirana za potrebe dubokog učenja i strojnog učenja. Razvijen od strane Google Brain tima, TensorFlow omogućava istraživačima i programerima izradu i treniranje modela strojnog učenja koristeći razne apstrakcije, od jednostavnih linearnih modela do složenih dubokih neuronskih mreža. Njegova arhitektura je fleksibilna i skalabilna, omogućujući raspodjelu zadataka na različite CPU i GPU jedinice, kao i na mobilne uređaje[9].

Keras

Keras je visoko modularna open-source biblioteka za duboko učenje, napisana u pythonu, koja pruža jednostavno i intuitivno sučelje za izradu i treniranje neuronskih mreža. Razvijena s ciljem omogućavanja brze eksperimentacije, Keras je kompatibilna s različitim backend bibliotekama za numeričke izračune, kao što je TensorFlow. Ova biblioteka pojednostavljuje proces izgradnje složenih modela dubokog učenja pružajući visoku razinu apstrakcije, čime korisnicima omogućava lako definiranje i treniranje modela kroz nekoliko linija koda. Keras dolazi s bogatom kolekcijom unaprijed definiranih slojeva, optimizatora, funkcija gubitka i alata za evaluaciju performansi, što dodatno ubrzava i olakšava proces istraživanja i razvoja[10].

3.3. Model

Cilj implementiranog modela je prepoznavanje regija sekvenca gdje se nalaze geni. Sastoji se od potpuno povezanih slojeva te kombinira konvolucijske i rekurentne neuronske slojeve.

Layer (type)	Output Shape	Param #
input_6 (InputLayer)	[(None, None)]	0
tf.one_hot_5 (TFOpLambda)	(None, None, 4)	0
bidirectional_10 (Bidirectional)	(None, None, 256)	136192
bidirectional_11 (Bidirectional)	(None, None, 256)	394240
dropout_5 (Dropout)	(None, None, 256)	0
conv1d_15 (Conv1D)	(None, None, 32)	24608
conv1d_16 (Conv1D)	(None, None, 64)	18496
time_distributed_20 (TimeDistributed)	(None, None, 64)	4160
time_distributed_21 (TimeDistributed)	(None, None, 32)	2080
time_distributed_22 (TimeDistributed)	(None, None, 1)	33

Total params: 579809 (2.21 MB)

Trainable params: 579809 (2.21 MB)

Non-trainable params: 0 (0.00 Byte)

Prikaz 3.3: Prikaz strukture implementiranog modela

3.3.1. One-hot sloj

Na početku modela se nalazi ulazni sloj koji šalje podatke one-hot sloju. Taj sloj nema u sebi umjetne neurone, nego on služi kako bi svaki broj u primljenom vektoru duljine 500 pretvorili u one-hot vektore. One-hot vektori su način predstavljanja kategorijskih podataka u obliku binarnih vektora koji sadrže jedan element vrijednost jedan i sve ostale elemente postave na nulu. U primjeru nukleotidnih baza one-hot vektor bi imao četiri elementa od kojih bi jedan imao vrijednost 1, a ostali nula. Pozicija te jedinice bi onda označavalo koju bazu reprezentira.

3.3.2. Rekurentni slojevi

Nakon one-hot sloja slijede rekurentni slojevi. Rekurentni slojevi su odlični za rad sa sekvencijskim podacima pošto oni pamte kontekst prije obrađenih podataka. U modelu prikazanom na Prikaz 3.3 koriste se dva LSTM sloja koji imaju dvosmjerni omotač. Dvosmjerni omotač osigurava da se ulazni podaci obrađuju dvosmjerno što znači da model generira svoj izlaz na temelju onoga što se nalazi prije i poslije trenutnog podatka. Nakon rekurentnih slojeva slijedi dropout sloj koji postavlja nasumično odabrane vrijednosti na nula. Droput sloj služi za sprječavanje pretreniranosti.

3.3.3. Konvolucijski slojevi

Nakon rekurentnih slojeva slijedi niz konvolucijskih slojeva. Konvolucijski slojevi su odlični zato što mogu klizeći po ulaznim podacima primijeniti razne filtere i izvući lokalne uzorke koje onda mogu prepoznati ako se pojave na nekom drugom djelu genoma. U modelu se koriste dva jednodimenzionalna konvolucijska sloja jer su oni odlični za sekvencijske podatke. Prvi sloj ima 32 filtera i veličinu jezgre 3. Ovaj sloj može identificirati uzorke unutar 3 uzastopne nukleotidne baze. Zatim sljedeći sloj koristi 64 filtera i veličinu jezgre 9. Svi konvolucijski slojevi koriste aktivacijsku funkciju ReLu.

3.3.4. Potpuno povezani slojevi

Zatim slijede dva potpuno povezana sloja. Za potpuno povezane slojeve koristimo ReLu aktivacijsku funkciju te TimeDistributed omotač. TimeDistributed omotač osigurava da se za svaki vremenski korak generira izlaz.

3.3.5. Izlazni sloj

Izlazni sloj se sastoji od potpuno povezanog sloja s jednim neuronom. Nad tim slojem je stavljen TimeDistrubuted omotač kako bi model na kraju za svaki ulazni podatak duljine 500 generirao izlaz duljine 500. Aktivacijska funkcija u ovom sloju je sigmoidalna. Ta funkcija će ograničiti izlaz na broj između 0 i 1 što će nama reprezentirati vjerojatnost pripadanja nuklotidne baze kodnoj regiji.

3.3.6. Važni hiperparametri

Funkcija gubitka

Korištena funkcija gubitka je binarna unakrsna entropija. Ona se koristi u problemima binarne klasifikacije. Njena osnovna svrha je kvantifikacija razlike između stvarne binarne oznake (koja može biti 0 ili 1) i vjerojatnosti koju je model predvidio.

Optimizator

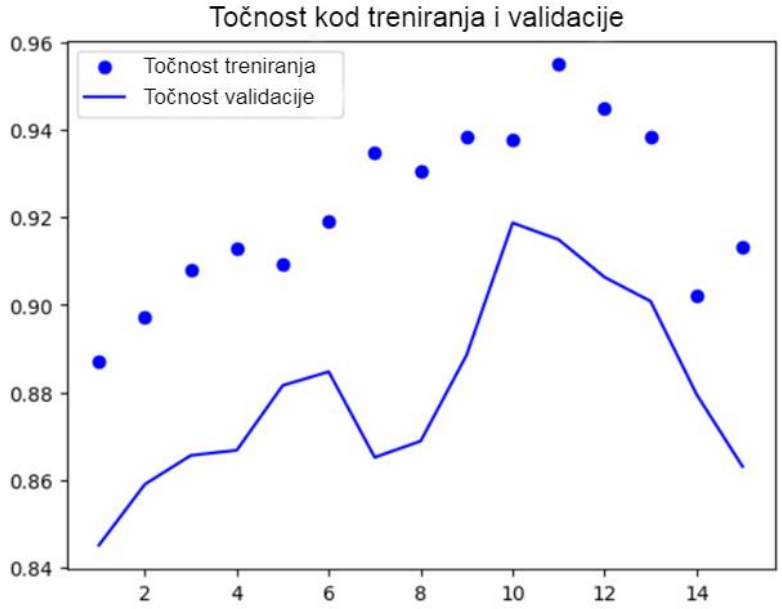
Korišteni optimizator je Adam. Adam je popularan zbog svoje efikasnosti i pouzdanosti u širokom spektru dubokih učenja. On automatski prilagođava brzinu učenja tijekom procesa optimizacije, što može ubrzati konvergenciju i poboljšati stabilnost treniranja.

Metrika

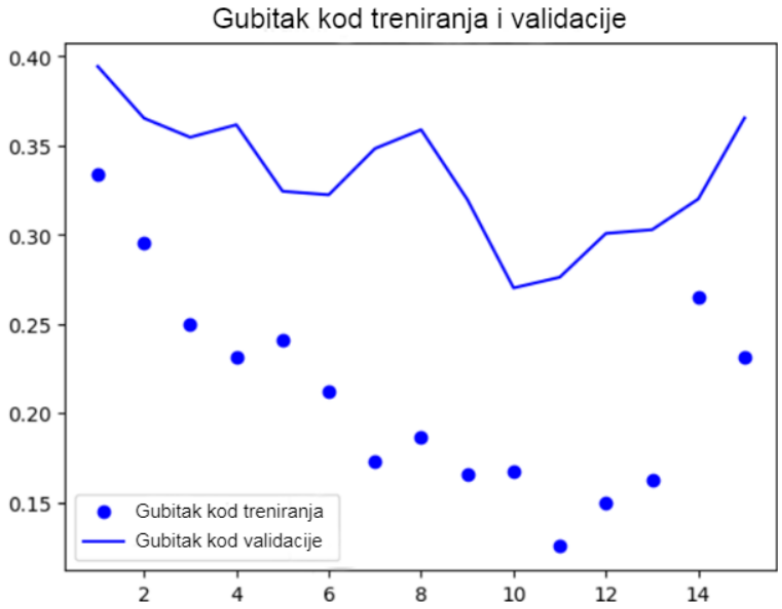
Korištena metrika kod treniranja modela je točnost. Točnost modela se izračunava kao postotak točno generiranih izlaza modela.

3.3.7. Treniranje modela

Tijekom treniranja modela možemo vidjeti napredak kroz epohe. Model je treniran na samo 15 epoha zbog nedovoljnih računalnih resursa. Na Sl. 3.1 možemo vidjeti kako točnost kod validacije počinje padati nakon desete epohe što znači da već tu dolazi do pretreniranosti modela. Također na Sl. 3.2 se vidi kako nakon desete epohe funkcija gubitka počinje rasti što isto indicira pretreniranost. Pretreniranost znači da model radi dobro na podacima na kojima je treniran ali loše generalizira. Zbog toga se pamti model prije nego što postane prenaučen.



Sl. 3.1: Graf točnosti kroz epohe treniranja



Sl. 3.2: Graf funkcije gubitka modela

3.4. Evaluacija modela

Evaluacija modela je ključna faza u razvoju bilo kojeg sustava za strojno učenje ili duboko učenje.

3.4.1. Podaci za evaluaciju

Evaluacija modela se radi na nikad viđenim podacima zato se koristi novi genom. Iz FASTA datoteke se učita DNA sekvenca, a iz GFF datoteke podaci o položajima gena na

genomu. Iz tih podataka se generira odgovarajući vektor nula i jedinica te se vektor baza pretvori u odgovarajuće brojeve (0-3 za A,C,G,T) i podijeli na blokove veličine 500 s pomakom od 100. Zatim se blokovi vektora brojeva i vektora nula i jedinica grupiraju. Ovaj put se podaci ne miješaju što će nam biti važno kasnije.

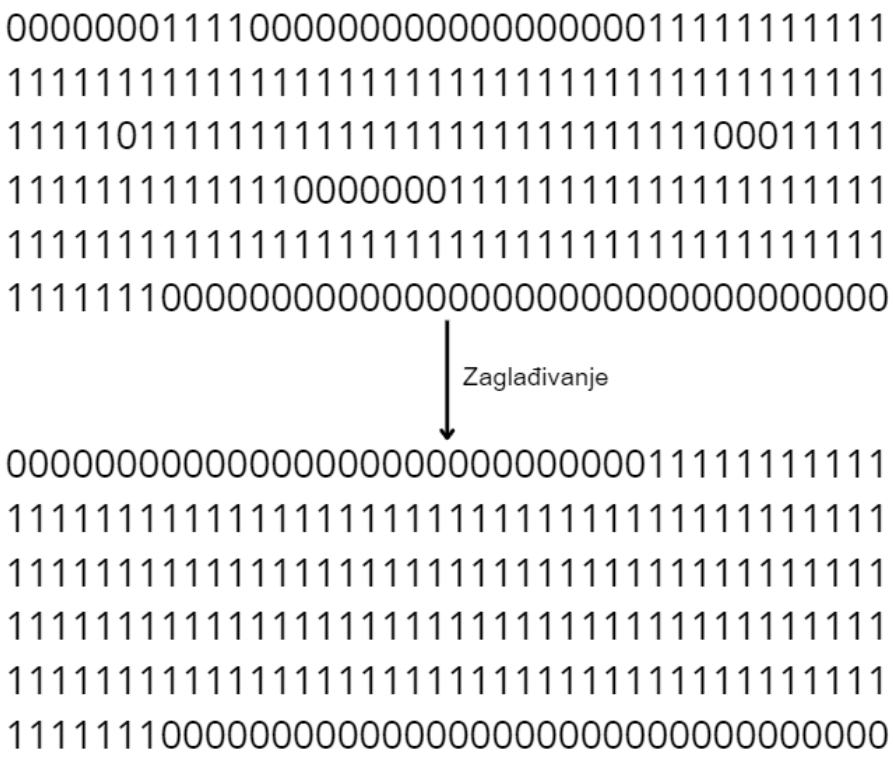
3.4.2. Rezultati modela

Model koristi metriku točnosti za evaluaciju. Točnost se mjeri kao broj točno predviđenih izlaza, odnosno broj ispravno predviđenih jedinica i nula u skupu podataka testnog genoma. Model procjenjuje točnost predikcija za svaki blok podataka u ulaznom skupu. Točnost modela iznosi 95.4%, što je vrlo dobro. Međutim, za precizne anotacije gena potrebna je dodatna obrada podataka.

3.4.3. Naknadna obrada podataka

Model pokazuje vrlo dobre rezultate u pogledu točnosti, ali krajnji cilj ovog rada je precizno određivanje početaka i krajeva gena unutar genoma, što zahtijeva dodatnu obradu podataka kako bi se dobile potpune anotacije. Prva faza obrade koristi metodu većinskog glasanja. Tijekom pripreme podataka genom smo podijelili na blokove od 500 nukleotida s pomakom od 100, što znači da će implementirani model procesirati svaki nukleotid pet puta. Analizirajući pet generiranih izlaza za svaki nukleotid možemo utvrditi prevladava li vrijednost jedinica ili nula, čime određujemo konačnu vrijednost za svaki nukleotid.

Nakon ovog koraka slijedi druga faza obrade, koja uključuje zaglađivanje izlaza mreže (Sl. 3.3). Budući da su geni obično kontinuirane regije unutar genoma, zaglađivanje pomaže u očuvanju ovog kontinuiteta. U generiranom vektoru mogu se pojaviti mali fragmenti jedinica koji su premali da bi bili klasificirani kao gen, ili mali fragmenti nula koji bi mogli podijeliti jedan gen u dva. Zaglađivanjem eliminiramo takve fragmente, osiguravajući koherentnost i kontinuitet gena. Ovo se postiže tako da svaki nukleotid postane prosječna vrijednost svojih najbližih susjeda, čime se uklanjaju izolirani fragmenti i osigurava glatki prijelaz između kodirajućih i nekodirajućih regija.



Sl. 3.3: Prikaz zaglađivanja

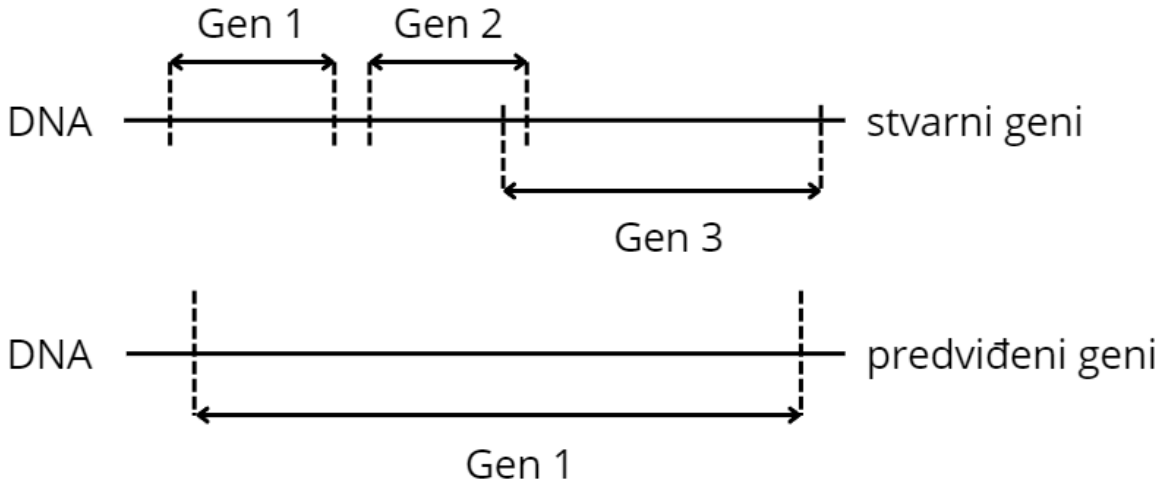
3.4.4. Konačna evaluacija

Nakon primjene obrade i dohvaćanja generiranih anotacija, rezultati se uspoređuju s podacima u GFF datoteci za testirani genom. Konačna evaluacija se izražava kao postotak točno anotiranih gena. Gen se smatra točno anotiranim ako se početak i kraj gena nalaze unutar 10 baza od stvarne vrijednosti. Takvom evaluacijom dobivamo rezultat od 29.47%. Mogući razlozi za tako nizak postotak:

1. Preklapanje gena: Kod genoma organizama može doći do preklapanja gena, što znači da je početak jednog gena smješten prije završetka prethodnog gena. U takvom slučaju model ne može raspoznati da se radi o dvama različitim genima nego će pretpostaviti da se radi o jednom dužem genu.
2. Mali razmaci između susjednih gena: Problem predstavljaju i mali razmaci između susjednih gena. Ako je razmak između dva susjedna gena oko deset nukleotidnih baza ili manje, tada bi proces zaglađivanja mogao prebrisati taj razmak čime bi se dva gena spojila u jedan.

Primjer problema preklapanja gena i malih razmaka između susjednih gena možemo vidjeti kod organizma Pseudomonas aeruginosa. Kada analiziramo anotacije gena iz GFF datoteke, možemo uočiti gen od pozicije 3169 do 4278, a zatim slijedeći gen od pozicije 4275 do 6695. Ovdje je jasno vidljivo preklapanje gena.

Što se tiče problema malih razmaka između susjednih gena, možemo uočiti gen od pozicije 2056 do 3159 i gen iz prethodnog primjera od pozicije 3169 do 4278. Model za ova tri gena generira anotaciju od pozicije 2060 do 6690, čime se može vidjeti kako je model spojio tri različita gena u jedan duži gen.



Sl. 3.4: Vizualni prikaz problema preklapanja gena i problema malih razmaka između susjednih gena

3.4.5. Poboljšanje rezultata modela

Jedan način za poboljšanje rezultata modela je korištenje modela za anotaciju gena samo na jednom DNA lancu. U DNA molekuli geni se mogu nalaziti na oba lanca, što se u GFF datotekama označava sa "+" i "-".

Ako promatramo gene samo s jednog DNA lanca, smanjujemo broj gena koji se preklapaju. Naime, može se dogoditi da se geni preklapaju, ali su smješteni na različitim lancima. Kada model pokušava predvidjeti gene na oba lanca istovremeno, dolazi do problema preklapanja. Promatranjem samo jednog lanca eliminiramo takve slučajeve i postižemo bolji rezultat. Isto vrijedi i za problem malih razmaka između gena.

Korištenjem ovog pristupa, model postiže točnost od 34.46%, što predstavlja napredak od 4.99%. Iako to nije značajan skok, ipak je dobar napredak.

3.4.6. GitHub

Implementirani model se može vidjeti i preuzeti sa javnog GitHub repozitorija na slijedećoj poveznici: https://github.com/FranKufrin/Model-ab-initio-detekcije-gena. Tamo se nalaze i upute za korištenje.

Zaključak

U ovom radu implementirao sam model duboke neuronske mreže za ab initio detekciju gena unutar genoma. Model pokazuje visoku točnost od 95.4% na testnom skupu podataka, što ukazuje na njegovu sposobnost ispravnog predviđanja pripadnosti nukleotidne baze kodirajućoj regiji. Međutim, za precizne anotacije gena potrebna je dodatna obrada podataka. Koristeći metode većinskog glasanja i zaglađivanja, nastojao sam poboljšati kontinuitet i točnost predikcija. Unatoč tome, konačna evaluacija pokazala je točnost anotacije gena od 29.47%, što ukazuje na izazove povezane s preklapanjem gena i malim razmacima između gena. Ovi rezultati naglašavaju potrebu za daljnjim poboljšanjima modela i obradom podataka kako bi se postigla veća preciznost u anotaciji gena.

Literatura

[1]Poveznica:https://edutorij-admin-api.carnet.hr/storage/extracted/7628/biologija-8/m01/j05/index.html; pristupljeno: 10. lipnja. 2024

[2] Dalbelo Bašić, B., Čupić, M., Šnajder, J. 11. prezentacija kolegija Uvod u umjetnu inteligenciju. FER, Zagreb, 2020.

[3] Chollet, F. Deep Learning with Python. 2. izdanje. Shelter Island, NY: Manning Publications, 2021.

[4] Martins, P. V. L. Gene prediction using deep learning (Magistarski rad). Mentor: Silva, R. C. C. d. S. F. FACULDADE DE ENGENHARIA DA UNIVERSIDADE DO PORTO, 2018.

[5] National Center for Biotechnology Information (NCBI). GenBank Overview. https://www.ncbi.nlm.nih.gov/genbank/, pristupljeno 11. lipnja 2024.

[6] National Center for Biotechnology Information (NCBI). About RefSeq. https://www.ncbi.nlm.nih.gov/refseq/about/, pristupljeno 11. lipnja 2024.

[7] Ensembl. GFF format. *Ensembl*. https://www.ensembl.org/info/website/upload/gff.html pristupljeno 11. lipnja 2024.

[8] National Center for Biotechnology Information (NCBI). FASTA Format Description. https://www.ncbi.nlm.nih.gov/genbank/fastaformat/, pristupljeno 12. lipnja 2024.

[9] TensorFlow. About TensorFlow. https://www.tensorflow.org/about, pristupljeno 12. lipnja 2024.

[10] Keras. About Keras. https://keras.io/about/, pristupljeno 12. lipnja 2024.

Sažetak

Razvoj dubokih neuronskih mreža doveo je do značajnih pomaka u mnogim područjima, uključujući bioinformatiku. Jedno od tih područja je detekcija gena unutar genoma različitih vrsta. U ovom radu fokusiramo se na ab initio metodu detekcije gena. Umjetne neuronske mreže su iznimno prikladne za ab initio detekciju gena zbog svoje sposobnosti učenja složenih i apstraktnih značajki iz podataka.

Implementirani model koristi kombinaciju konvolucijskih, rekurentnih i potpuno povezanih slojeva, čime se iskorištavaju prednosti svake od tih arhitektura. Model je treniran i testiran na javno dostupnim podacima genoma bakterija. Rezultati evaluacije na razini pojedinačne nukleotidne baze pokazali su se vrlo dobrima, no glavni cilj rada je točno određivanje početaka i krajeva gena u genomu, odnosno generiranje preciznih anotacija. Iako su rezultati anotacija trenutno niskog postotka, što može biti razočaravajuće, to otvara mogućnosti za daljnje poboljšanje modela, poput isprobavanja novih arhitektura i poboljšanja metoda naknadne obrade podataka, s ciljem dobivanja preciznijih anotacija.

Ključne riječi: Bioinformatika, Genom, Detekcija gena, Anotacija gena, Ab initio, Duboko učenje, Rekurentne neuronske mreže, Konvolucijske neuronske mreže

Abstract

The development of deep neural networks has led to significant advancements in many fields, including bioinformatics. One of these areas is gene detection within the genomes of various species. In this study, we focus on the ab initio method of gene detection. Artificial neural networks are exceptionally well-suited for ab initio gene detection due to their ability to learn complex and abstract features from data.

The implemented model uses a combination of convolutional, recurrent, and fully connected layers, leveraging the advantages of each architecture. The model was trained and tested on publicly available bacterial genome data. The evaluation results at the single nucleotide base level were very good, but the main goal of the study is to accurately determine the start and end points of genes in the genome, to generate precise annotations. Although the annotation results are currently at a low percentage, which may be disappointing, this opens up opportunities for further improvement of the model, such as testing new architectures and enhancing data post-processing methods to achieve more precise annotations.

Keywords: Bioinformatics, Genome, Gene Detection, Gene Annotation, Ab initio, Deep Learning, Recurrent Neural Networks, Convolutional Neural Networks